Selection via Proxy: воспроизведение

Active Learning на CIFAR-10: random, отбор ResNet-164 и отбор ResNet-20. Девять запусков с бюджетом 25 000 изображений.

1. Метод

Coleman et al., Selection via Proxy: Efficient Data Selection for Deep Learning, ICLR 2020 [1]. В SVP критерий отбора вычисляет proxy-модель с меньшей стоимостью обучения. Итоговый классификатор target обучается с нуля на выбранных данных. Качество оценивается по ошибке target на тестовом наборе.

Рассматриваются Active Learning и Core-set Selection. В Active Learning размечен начальный набор. В каждом раунде модель отбирает объекты для разметки, после чего обучается с нуля на накопленном наборе. В экспериментах Core-set Selection метки исходного набора известны. Для итогового обучения отбирается одно подмножество.

Критерий отбора и архитектура target одинаковы при сравнении режимов. Стоимость proxy снижается за счёт архитектуры или числа эпох. Веса proxy в target не передаются.

Критерий	**Как выбираются примеры**	**Задача в статье**
Least confidence	Наибольшее значение 1 минус максимальная вероятность класса	Active Learning
Greedy k-centers	Поочерёдно добавляется пример, наиболее удалённый от ближайшего выбранного в пространстве признаков	Обе задачи
Forgetting events	Наибольшее число переходов от верного ответа к ошибке при обучении; никогда не распознанным примерам задаётся бесконечный счётчик	Core-set Selection
Max entropy	Наибольшая энтропия предсказанного распределения	Core-set Selection

Авторы измеряют корреляцию рангов между моделями разного размера. Для forgetting events на CIFAR-10 корреляция ResNet-20 и ResNet-164 составляет около 0.90; для entropy и k-centers она ниже. На Amazon Review Full отбор по неуверенности не снизил ошибку относительно случайного отбора.

Результаты статьи для CIFAR-10: least confidence, бюджет 25 000 изображений, итоговая ResNet-164. Приведены среднее и стандартное отклонение по трём запускам, Table 3 [1].

Отбор	**Test error, %**	**Ускорение отбора**
Случайный	7,50 ± 0,11	-
ResNet-164	5,30 ± 0,06	1,0×
ResNet-20	5,40 ± 0,41	7,2×

Время отбора включает обучение выбирающих моделей и вычисление критерия на пуле. Итоговое обучение в этот замер не входит.

2. Эксперимент

CIFAR-10, Active Learning с least confidence. Каждая модель обучается 181 эпоху. Конечный размеченный набор содержит 25 000 изображений, исходный пул - 50 000, тест - 10 000.

Настройка	**Код авторов**	**Эксперимент**
Train-пул / test	50 000 / 10 000	50 000 / 10 000
Начальный набор	1 000	1 000
Накопленные размеры	1 000, 5 000, 10 000, 15 000, 20 000, 25 000	1 000, 5 000, 10 000, 15 000, 20 000, 25 000
Эпохи и этапы	181: 1 / 90 / 45 / 45	181: 1 / 90 / 45 / 45
LR по этапам	0,01 / 0,1 / 0,01 / 0,001	0,01 / 0,1 / 0,01 / 0,001
Повторения	3 запуска	Seed 0, 1, 2

Режимы: random выбирает случайно без повторов; target выбирает через ResNet-164; proxy выбирает через ResNet-20. Во всех режимах итоговая модель - новая ResNet-164, обученная на 25 000 выбранных изображений. Для одного seed начальные 1 000 изображений одинаковы.

В режимах target и proxy модель отбора обучается с нуля в каждом из пяти раундов. Для оставшегося пула вычисляется 1 - max(softmax(logits)). По убыванию этой оценки выбираются 4 000, 5 000, 5 000, 5 000 и 5 000 изображений. Метки CIFAR-10 имитируют ответ разметчика; при ранжировании они не используются.

PreAct ResNet-20 и ResNet-164 адаптированы из кода авторов [2]. Обучение: cross entropy, SGD, batch 128, momentum 0,9, weight decay 0,0005. Для train применяются random crop 32×32 с padding 4 и horizontal flip. Для выбора и теста используется только нормализация. Протокол: FP16 с autocast и GradScaler, последние веса, без выбора эпох по test.

Оборудование: RTX 4070 Ti SUPER, 16 ГБ. Окружение: Python 3.12, PyTorch 2.11.0+cu128, torchvision 0.26.0. Зависимости зафиксированы в uv.lock.

Проверены размер, уникальность и вложенность каждого набора, диапазон индексов train и одинаковый старт режимов. Train и pool используют одни исходные изображения с разными преобразованиями. Test используется только после итогового обучения. Все девять запусков прошли аудит конфигураций, 181 эпохи каждого обучения, FP16, конечности метрик, согласованности CSV и JSON. Хеши исходников серии сверены с source.json.

Запуск из hw2: uv run run.py --mode all --seed N --device cuda. Значения N: 0, 1, 2.

3. Результаты

Test error = 100 - accuracy. Среднее и выборочное std (ddof=1) по seed 0, 1, 2; для времени приведено среднее. Результаты: results/full/runs.csv.

Режим	Test error, %	Отбор, с	Итоговое обучение, с
random	7,72 ± 0,16	0,0016	1630,64
target	5,54 ± 0,03	3361,61	1631,31
proxy	5,57 ± 0,19	1411,98	1632,12

Ускорение отбора target / proxy: 2,38 ± 0,01 раза; среднее и выборочное std отношений по seed. Отбор и итоговое обучение: 83,22 мин для target, 50,73 мин для proxy; отношение средних времён - 1,64 раза. Фактическое время девяти запусков: 484,03 мин (8 ч 4 мин), по журналу серии.

Время отбора включает обучение всех моделей отбора и ранжирование; итоговое обучение измеряется отдельно. CUDA синхронизируется на границах замеров. Тест и построение графиков в эти замеры не входят.

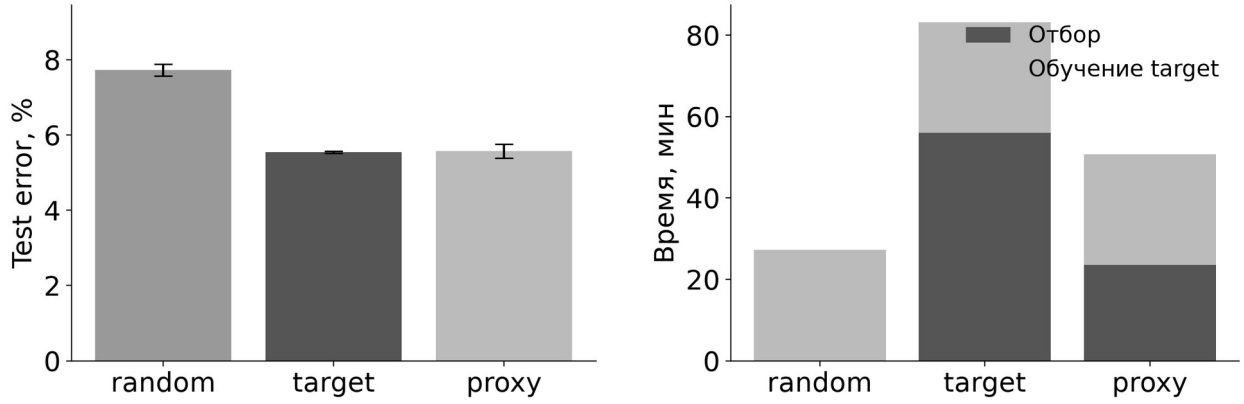


Рис. 1. Слева test error, среднее ± std. Справа среднее время отбора и итогового обучения. CIFAR-10, бюджет 25 000, FP16, три seed.

Минимальная средняя ошибка у target: 5,54%. Random выше на 2,18 п.п., proxy - на 0,03 п.п. Стандартное отклонение: 0,03 п.п. у target и 0,19 п.п. у proxy.

Средние ошибки random, target и proxy выше значений Table 3 статьи на 0,22, 0,24 и 0,17 п.п. при бюджете 25 000. Ускорение отбора - 2,38 ± 0,01 раза против 7,2 в статье. Proxy снижает стоимость отбора при близких средних ошибках target и proxy.

Источники

1. Coleman et al. Selection via Proxy: Efficient Data Selection for Deep Learning. ICLR 2020. arXiv:1906.11829v3. Статья, локальная копия paper.pdf.
2. Код авторов, commit 348f90ac9caaa393117f1968f1aedf05dbfbac0f.