Selection via Proxy

Efficient Data Selection for Deep Learning

Cody Coleman и соавторы
Stanford University, 2020

Active Learning и Core-set Selection

Active Learning

Исходные данные: пул без меток и небольшой размеченный набор.

В каждом раунде модель отбирает объекты для разметки. Объём разметки ограничен бюджетом.

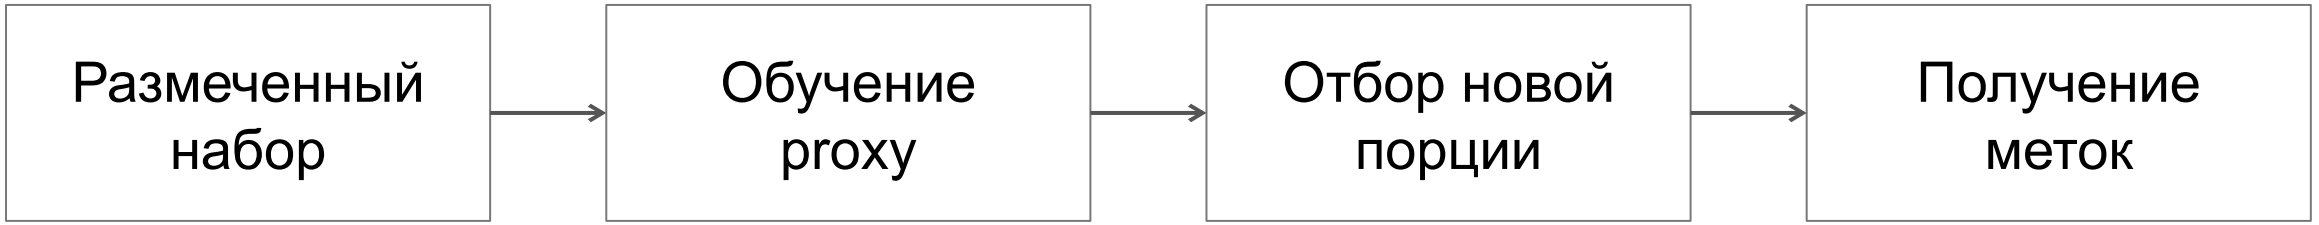
Core-set Selection

Исходные данные: обучающий набор с известными метками.

Для обучения target отбирается подмножество. Критерий сравнения: ошибка на тесте.

Без proxy модель отбора обучается в каждом раунде Active Learning.
Для core-set она обучается на исходном наборе.

Отбор с proxy-моделью



В каждом раунде proxy обучается с нуля
на накопленном размеченном наборе.

После отбора target обучается с нуля.
Во всех режимах используется одна архитектура target.

Стоимость отбора снижается за счёт архитектуры proxy или числа эпох.

Least confidence и Max entropy

Least confidence

$u(x) = 1 - \max p(y \mid x)$

max p = 0,90: u = 0,10
max p = 0,40: u = 0,60

Отбор по убыванию u(x).
Достаточно предсказаний модели, метки кандидатов не используются.

Max entropy

$H(x) = -\Sigma\, p(y \mid x) \log p(y \mid x)$

Учитывает всё распределение вероятностей, а не только максимум.

Отбор по убыванию H(x).
В статье применяется для core-set.

k-centers и Forgetting events

Greedy k-centers

Признаки φ(x) из последнего скрытого слоя модели.

Оценка кандидата: расстояние до ближайшего объекта в выбранном подмножестве.

На каждом шаге добавляется кандидат с максимальной оценкой. Метод применяется в обеих задачах.

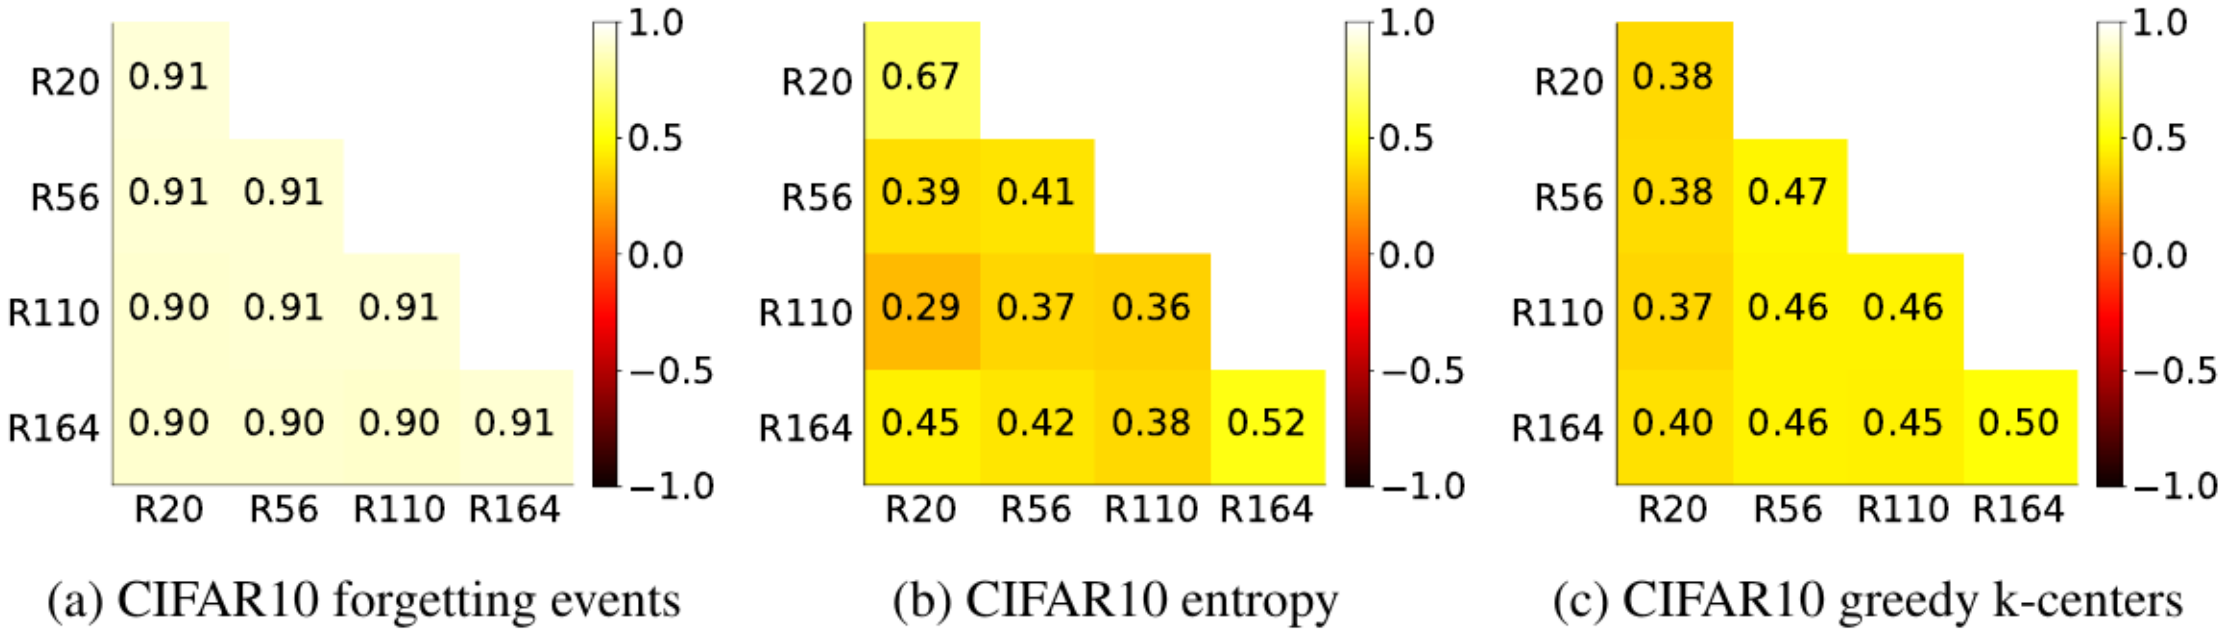
Forgetting events

Число переходов «верно → неверно» при обучении на исходном наборе.

Отбор объектов с наибольшим числом переходов.

Для объектов без верных ответов счётчик равен бесконечности. Метод применяется для core-set.

Корреляция рангов между моделями



(a) CIFAR10 forgetting events (b) CIFAR10 entropy (c) CIFAR10 greedy k-centers

Числа показывают корреляцию рангов Спирмена.
На диагонали сравниваются разные запуски одной архитектуры.

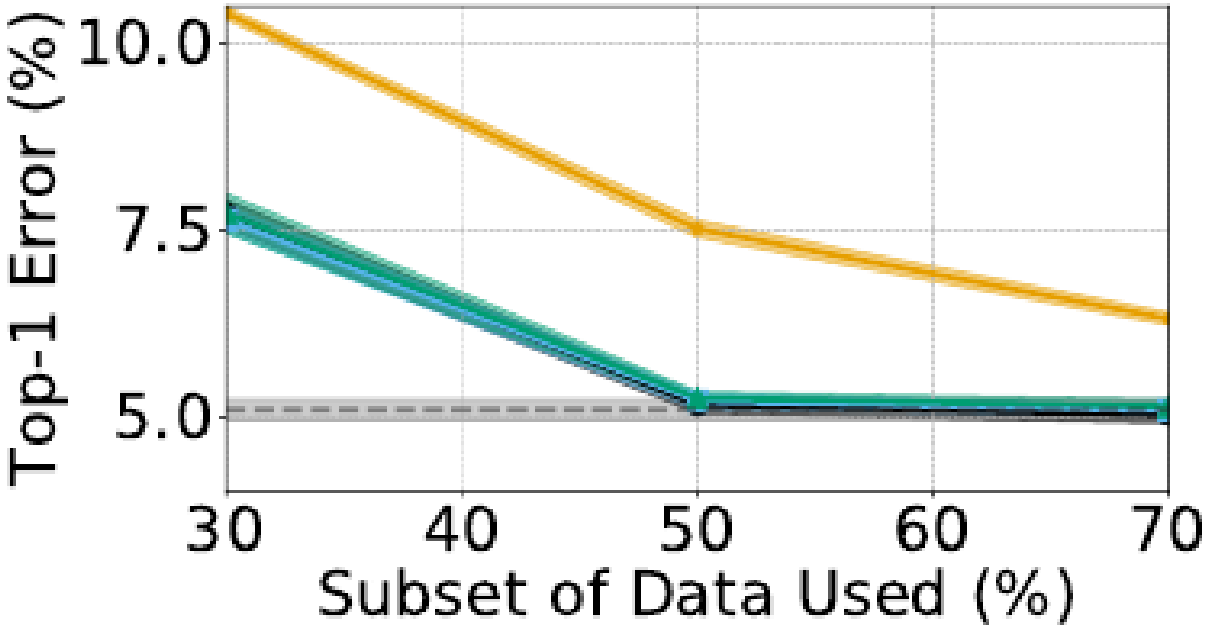
Для forgetting events R20 и R164 дают $\rho \approx 0{,}90$.
Для entropy и k-centers корреляция ниже.

Active Learning в статье

Отбор	Error при 10 000	Error при 25 000
Random	12,9 ± 0,37%	7,5 ± 0,11%
ResNet-164	10,4 ± 0,38%	5,3 ± 0,06%
ResNet-20	10,5 ± 0,42%	5,4 ± 0,41%

Итоговая модель во всех строках: ResNet-164.
Ускорение отбора через ResNet-20: 5,8× при 10 000; 7,2× при 25 000.

Core-set в статье



(a) CIFAR10 forgetting events

Forgetting events

Чёрная линия: отбор ResNet-164.
Голубая: отбор ResNet-20.
Оранжевая: random.
Пунктир: полный набор.

ResNet-20 сохраняет ошибку около 5% на половине данных. Полное время сокращается примерно в 1,6 раза.

На ImageNet удалить значимую долю данных без потери качества не удалось.

Параметры эксперимента

Параметр	Значение
Данные	CIFAR-10: пул 50 000, test 10 000
Размеры train	1 000 / 5 000 / 10 000 / 15 000 / 20 000 / 25 000
Модели отбора	random / ResNet-164 / ResNet-20
Итоговая модель	ResNet-164 для всех трёх режимов
Обучение	181 эпоха, FP16, batch 128, SGD
Повторы	seed 0, 1, 2; одинаковый старт

LR 0,01 / 0,1 / 0,01 / 0,001 на 1 / 90 / 45 / 45 эпох.
Momentum 0,9; weight decay 0,0005; autocast и GradScaler.

Метрики и проверка данных

Качество: test error последних весов ResNet-164.
Среднее и выборочное std (ddof=1) по трём seed.

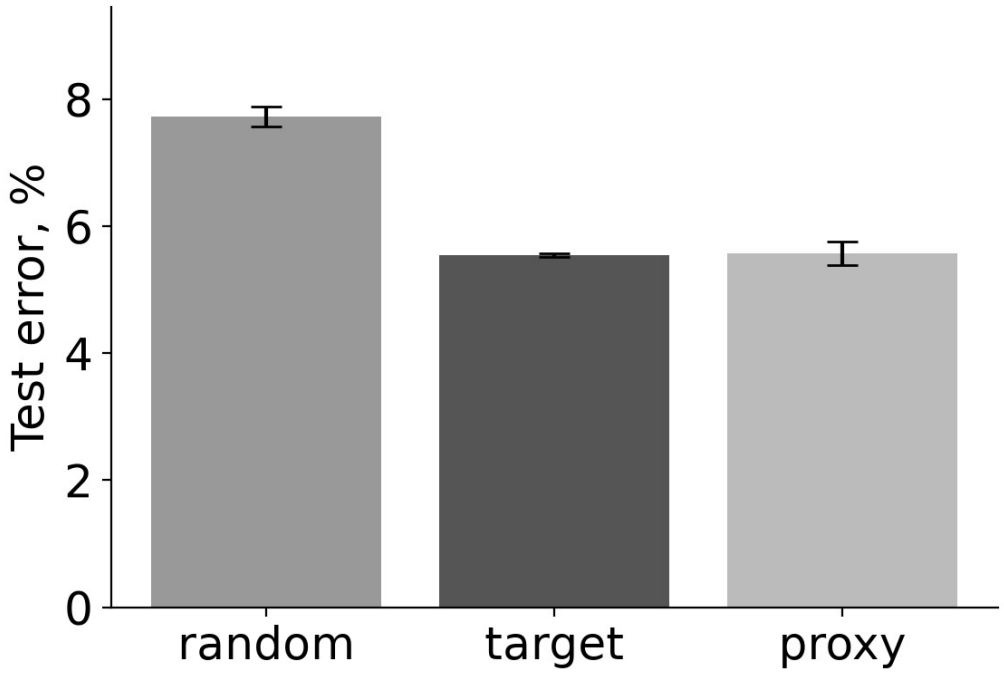
Время отбора: обучение выбирающих моделей и проход по пулу.
Итоговое обучение target измеряется отдельно.

Ускорение: target / proxy для каждого seed, затем среднее и std

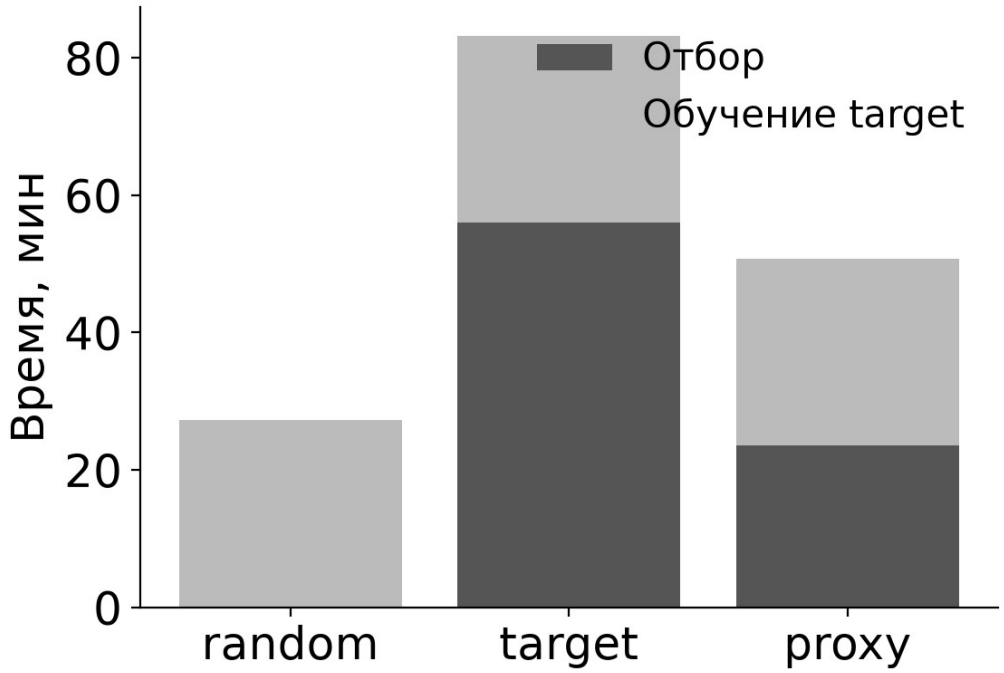
Индексы только из train, без повторов. Test используется в конце.
Размеры накопленных наборов проверяются после каждого раунда.
Перед замером времени вызывается CUDA synchronize.

Результаты эксперимента

Test error



Время



Ускорение отбора: 2,38 ± 0,01 раза.
Ошибка proxy выше target на 0,03 процентного пункта.

Сравнение режимов

Режим	Test error, %	Отбор, с	Итоговое обучение, с
random	7,72 ± 0,16	0,0016	1630,64
target	5,54 ± 0,03	3361,61	1631,31
proxy	5,57 ± 0,19	1411,98	1632,12

Минимальная средняя ошибка у target: 5,54%.
Proxy отличается на 0,03 п. п.; оба режима лучше random.

FP16, 181 эпоха, бюджет 25 000; три seed.
Фактическое время всей серии: 484,03 мин (8 ч 4 мин).